DOI: 10.3785/j.issn.1008-973X.2024.10.005

基于秃鹰搜索算法优化的三维多无人机低空突防

温夏露[1,2]，黄鹤[1,2]，王会峰[2]，杨澜[1]，高涛[3]
(1. 长安大学 西安市智慧高速公路信息融合与控制重点实验室，陕西 西安 710064；2. 长安大学 电子与控制工程学院，陕西 西安 710064；3. 长安大学 数据科学与人工智能研究院，陕西 西安 710064)

摘 要：三维空间环境复杂，多无人机的低空突防航迹规划计算量大，现有多目标秃鹰搜索算法存在求解易趋于中心点及精度低的缺陷，为此提出基于改进多目标秃鹰搜索算法 (IMBES) 的三维多无人机低空突防方法. 构建三维环境模型、威胁源模型、无人机物理约束模型、多无人机协同约束模型以及路径平滑度约束模型，确定多目标代价函数. 设计耦合混沌映射初始化，有效提高初始化种群质量；设计基于“侦察鹰”的自适应高斯游走策略，平衡开发与搜索能力；引入快速非支配排序，进一步提高算法效率. 利用秃鹰位置与无人机速度、转弯角度、爬升角度的对应关系，采用 IMBES 高效搜索无人机构型空间，找到最优的帕累托前沿. 实验结果表明，IMBES 的成功率为 70.5%. 与现有路径规划方法相比，所提方法的优化能力强、能耗低，适用于多无人机协同低空突防.

关键词：多无人机；低空突防；自主避障；多目标算法；秃鹰搜索算法
中图分类号：TP 393　　**文献标志码：**A　　**文章编号：**1008−973X(2024)10−2020−11

Optimization of 3D multi-UAVs low altitude penetration based on bald eagle search algorithm

WEN Xialu[1,2], HUANG He[1,2], WANG Huifeng[2], YANG Lan[1], GAO Tao[3]
(1. *Xi'an Key Laboratory of Intelligent Expressway Information Fusion and Control*, *Chang'an University*, *Xi'an* 710064, *China*;
2. *School of Electronics and Control Engineering*, *Chang'an University*, *Xi'an* 710064, *China*;
3. *School of Data Science and Artificial Intelligence*, *Chang'an University*, *Xi'an* 710064, *China*)

Abstract: In response to the complex three-dimensional space environment and the high computational complexity of low altitude penetration path planning for multi-UAVs, the existing multi-objective bald eagle search algorithm has the shortcomings of easily approaching the center point and low accuracy. A 3D multi-UAVs low altitude penetration method based on the improved multi-objective bald eagle search algorithm (IMBES) was proposed. Models for the 3D environment, threat sources, UAV physical constraints, multi-UAVs cooperative constraints, and path smoothness were constructed to define a multi-objective cost function. A coupling chaotic mapping initialization was designed to enhance the quality of the initial population. An adaptive Gauss walk strategy based on the “scout eagle” was devised to balance development and search capabilities. Fast non-dominated sorting was introduced to further enhance algorithm efficiency. By leveraging the correspondence between the bald eagle position and UAV speed, turning angle, and climbing angle, the IMBES efficiently explored the UAV configuration space to identify the optimal Pareto front. Experimental results showed that the success rate of the IMBES was 70.5%. Compared with existing path planning methods, the proposed method demonstrates strong optimization capabilities and low energy consumption, making it suitable for collaborative low-altitude penetration by multiple UAVs.

Key words: multi-UAVs; low altitude penetration; autonomous obstacle avoidance; multi-objective algorithm; bald eagle search algorithm

收稿日期：2023−10−18.　　**网址：**www.zjujournals.com/eng/article/2024/1008-973X/202410005.shtml
基金项目：国家自然科学基金资助项目(52172324, 52172379)；中央高校基本科研业务费专项资金重点科研平台建设计划水平提升项目(300102324501)；西安市智慧高速公路信息融合与控制重点实验室(长安大学)开放基金资助项目(300102323502).
作者简介：温夏露(2000—)，女，硕士生，从事无人机路径规划研究. orcid.org/0000-0002-9846-5302. E-mail: 2022132053@chd.edu.cn
通信联系人：黄鹤，男，教授，博导. orcid.org/0000-0002-7149-0460. E-mail: huanghe@chd.edu.cn

低空突防是无人机（unmanned aerial vehicle, UAV）作战中的重要环节[1], 其目标是在满足各项约束的基础上, 设计算法规划出从起点到终点能够有效避开威胁源的低能耗路线. 单无人机突防能力略显不足, 因此多无人机协同规划逐渐成为无人机集群化、自主化和智能化的发展关键和研究热点[2]. 由于作战环境形势交错、复杂性强, 且多无人机在航迹规划时受到众多条件的约束, 亟须建立更精确的模型并设计更高效的算法. 元启发式算法被认为是处理单目标和多目标问题的标准优化方法[3], 这些方法在复杂和动态环境（包括战场、救援任务和多无人机路径优化等场景）中表现出色. 元启发式算法大致分为 4 类：进化算法[4]、基于物理的算法[5]、基于群体的算法[6] 和混合元启发算法[7]. 其中基于群体的算法也称群体智能（swarm intelligence, SI）[8] 算法, 它不仅克服了进化算法收敛慢和基于物理的算法受模型限制的缺陷, 而且计算成本适中. 此外, 该方法强调合作和信息共享处理集体智能问题, 对初始条件的敏感性较低, 适用于三维多无人机低空突防. 群体智能算法已被应用于多无人机航迹规划. Eun 等[9] 在二维地图上利用遗传算法讨论多无人机组的任务分配和轨迹规划问题, 但未充分考虑三维地形和威胁源约束的影响. 杜云等[10] 考虑无人机性能、威胁源、时空协同等约束, 利用改进的粒子群算法求解最优路径集合, 但利用单目标代价函数寻优时, 权重设置受主观因素影响较大. 闫少强等[11] 提出改进麻雀搜索算法（game predatory sparrow search algorithm, GPSSA）, 在复杂三维地形中求解单无人机及多无人机航迹规划中都取得了较好的规划效果, 但协同目标函数仍依赖单目标群智能算法的寻优性能, 影响了算法效率. 袁梦顺等[12] 将各项约束和代价转换为非支配排序遗传算法-Ⅲ (non-dominated sorting genetic algorithm-Ⅲ, NSGA-Ⅲ) 的数值指标, 避免了单目标问题加权的主观性, 但算法应用的建模场景复杂程度不高. 上述研究虽然能够实现多无人机协同航迹规划, 但优化效果和迭代收敛速度仍有提升空间.

秃鹰搜索算法 (bald eagle search, BES)[13] 是新型元启发式算法, 具有收敛速度快, 适应性强, 模型易修改等特点. 与同类型的如麻雀算法 (sparrow search algorithm, SSA)、鹈鹕算法 (pelican optimization algorithm, POA)、水母算法 (jellyfish search, JS) 和蜣螂算法 (dung beetle optimizer, DBO) 相比, BES 的性能更优, 且在极坐标系中进行搜索的寻优方式独特, 更适用于高效搜索无人机构型空间. 多无人机航迹规划问题通常涉及多个冲突的目标, 使用单目标群智能算法只能解决单个目标或通过加权方式平衡多个目标, 求解精度欠缺. 多目标算法能够在优化过程中同时优化多个目标, 找到一系列平衡解, 提供多样化决策选择. BES 本身搜索能力不足, 寻优过程易趋于中心点, 选取局部最优航迹时缺陷较大. 为了使多无人机在航迹规划中实现快速寻优, 获取到具有高精度的较优路径, 本研究提出改进的多目标秃鹰搜索算法 (improved multi-objective bald eagle search algorithm, IMBES), 应用于多无人机协同低空突防.

1 多无人机三维避障环境建模

假设静态地形环境已知, 根据已知参数构建三维山地模型、威胁源模型、单无人机物理约束模型、多无人机协同约束模型以及路径平滑度约束模型, 结合各约束确立多目标代价函数.

1.1 地形约束

建模时地形约束有 2 种, 分别是地势低平的平原和地势较高的山丘[14-15], 其中山丘对地形代价影响较大. 构建山丘三维模型为

$$H(x,y)=h\cdot\exp\left(-\frac{(x-x_0)^2}{\omega_1}-\frac{(y-y_0)^2}{\omega_2}\right)^2. \tag{1}$$

式中：(x, y) 为三维空间点的坐标, (x_0, y_0) 为山丘的中心坐标, h 为山丘高度, ω_1、ω_2 均为山丘陡峭度. 无人机飞行过程中, 离地面高度高于 0.1 km 即视作安全. 航迹点地形威胁代价函数为

$$f_{H,j}^i=\begin{cases}K_H^i, & h_j^i-H_j^i\leqslant 0;\\ K_H^{i'}, & 0<h_j^i-H_j^i\leqslant 0.1;\\ 0, & h_j^i-H_j^i>0.1.\end{cases} \tag{2}$$

式中：$f_{H,j}^i$、h_j^i、H_j^i、K_H^i 及 $K_H^{i'}$ 分别为第 i 架 UAV 第 j 个航迹点对应的地形代价、海拔高度、地形高度和 2 个相异的地形威胁系数. 为了更大程度地接近实际, 低空突防须考虑高程代价. 各航迹点的高程代价为

$$f_{G,j}^i=h_j^i. \tag{3}$$

限定无人机飞行边界以保证可控性, 根据地形情况设定飞行水平范围及最大飞行高度.

1.2　威胁模型约束

在建模无人机突防过程中，雷达探测、防空火炮、地空导弹和禁飞区等被认为是主要的威胁源. 为了简化建模，根据威胁的性质算出各威胁源的作用半径和作用空间形状，以等效地形代替[16]. 假设距离威胁源中心越近，威胁代价越大；反之，则越低. 将威胁源等效为数学模型，定义每个航迹点在威胁区域的计算代价为

$$f_{P,j}^{m,i}=\begin{cases}0, & |(x,y)_j^i-C_n^m|\geqslant R_{\max,n}^m;\\ K_{\text{thr}}^m|R_{\max n}^m-|(x,y)_j^i-C_n^m||, & \text{其他}.\end{cases} \tag{4}$$

式中：K_{thr}^m为第 m 类威胁源的修正系数，C_n^m、$R_{\max,n}^m$分别为第 m 类的第 n 个威胁源的中心及其最大作用半径，$(x,y)_j^i$、$f_{P,j}^{m,i}$为第 i 架 UAV 第 j 个航迹点对应的笛卡尔坐标和威胁源代价.

1.3　单无人机约束

单无人机在飞行过程中受自身的物理约束，主要包括最大拐弯角 α、最大下滑及爬升角 β、续航时间 t_{d} 以及发动机功率 W 约束[17]，表达式分别为

$$J_{\alpha,j}^i=\begin{cases}0, & \alpha\leqslant\alpha_{\max}^i;\\ K_\alpha, & \alpha>\alpha_{\max}^i.\end{cases} \tag{5}$$

$$J_{\beta,j}^i=\begin{cases}0, & \beta\leqslant\beta_{\max}^i;\\ K_\beta, & \beta>\beta_{\max}^i.\end{cases} \tag{6}$$

$$J_{t_{\text{d}},j}^i=\begin{cases}0, & t_{\text{d}}\leqslant t_{\max}^i;\\ K_{t_{\text{d}}}, & t_{\text{d}}>t_{\max}^i.\end{cases} \tag{7}$$

$$J_{W,j}^i=\begin{cases}0, & W\leqslant W_{\max}^i;\\ K_W, & W>W_{\max}^i.\end{cases} \tag{8}$$

式中：K_α、K_β、$K_{t_{\text{d}}}$、K_W 分别为拐弯角、俯仰角、续航时间和无人机发动机功率的威胁系数；$\alpha_{\max}^i$、$\beta_{\max}^i$、$t_{\max}^i$和$W_{\max}^i$ 分别为第 i 架 UAV 对应的最大拐弯角、俯仰角、续航时间和无人机发动机功率；$J_{\alpha,j}^i$、$J_{\beta,j}^i$、$J_{t_{\text{d}},j}^i$和$J_{W,j}^i$分别为第 i 架 UAV 第 j 个航迹点对应的不同约束的代价函数. 第 i 架 UAV 第 j 个航迹点自身约束代价函数为

$$f_{J,j}^i=J_{\alpha,j}^i+J_{\beta,j}^i+J_{t_{\text{d}},j}^i+J_{W,j}^i. \tag{9}$$

1.4　路径平滑度约束

路径平滑是生成路径可行的必要条件，通过计算转弯速率和爬坡速率得到[18]. 如图 1 所示，转弯角 ϕ_j^i 为投影在水平面 oxy 的 2 个连续路径段 $\overrightarrow{P_j^{i'}P_{j+1}^{i'}}$ 和 $\overrightarrow{P_{j+1}^{i'}P_{j+2}^{i'}}$ 之间的夹角. 设 $\boldsymbol{k}$ 为 z 轴方向的单位向量，则投影向量计算式为

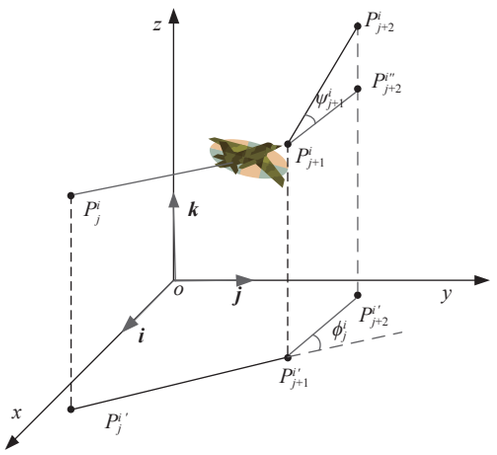


图 1　转弯和爬坡角度图

Fig.1　Diagram of turning and climbing angles

$$\overrightarrow{P_j^{i'}P_{j+1}^{i'}}=\boldsymbol{k}\times(\overrightarrow{P_j^iP_{j+1}^i}\times\boldsymbol{k}). \tag{10}$$

转弯角为

$$\phi_j^i=\arctan\left(\frac{\left\|\overrightarrow{P_j^{i'}P_{j+1}^{i'}}\times\overrightarrow{P_{j+1}^{i'}P_{j+2}^{i'}}\right\|}{\overrightarrow{P_j^{i'}P_{j+1}^{i'}}\cdot\overrightarrow{P_{j+1}^{i'}P_{j+2}^{i'}}}\right). \tag{11}$$

爬升角 Ψ_j^i 是路径段 $\overrightarrow{P_j^iP_{j+1}^i}$ 与该路径段在水平面上的投影 $\overrightarrow{P_j^{i'}P_{j+1}^{i'}}$ 的夹角，计算式为

$$\psi_j^i=\arctan\left((z_{j+1}^i-z_j^i)\Big/\left\|\overrightarrow{P_j^{i'}P_{j+1}^{i'}}\right\|\right). \tag{12}$$

综上，第 i 架 UAV 路径平滑度代价为

$$f_s^i=\lambda_1\sum_{j=1}^{n-2}\phi_j^i+\lambda_2\sum_{j=1}^{n-1}\left|\psi_j^i-\psi_{j-1}^i\right|. \tag{13}$$

式中：λ_1、λ_2 分别为转弯角和爬升角的惩罚系数.

1.5　多无人机协同约束模型

多无人机系统在执行协同打击作战任务时，须在保证同时到达同一目标点的前提下，尽可能实现各无人机的飞行路径足够分散，即实现“分散突防、集中打击”的作战效果，从战术角度保证以最小代价实现最大打击效果[19]. 设时间和空间协同约束系数$C_{i,j}^{\text{t}}$和$C_{i,j}^{\text{d}}$分别为

$$C_{i,j}^{\text{t}}=\begin{cases}P/\left|t_i-t_j\right|, & \max\left[t_{i,\min},t_{j,\min}\right]<\min\left[t_{i,\max},t_{j,\max}\right];\\ 0, & \text{其他}.\end{cases} \tag{14}$$

$$C_{i,j}^{\text{d}}=\begin{cases}P'/\sum_{k=1}^{n}d_k, & d_k<0.3\ \text{km};\\ 0, & \text{其他}.\end{cases} \tag{15}$$

式中: P、P'均为足够大的常数, 本研究均取为 100; $|t_i - t_j|$为无人机 i 和无人机 j 到达目标点的时间差; $C_{i,j}^{\mathrm{t}}$为无人机之间的时间协同系数; 时间协同条件为 $\max[t_{i,\min}, t_{j,\min}]<\min[t_{i,\max}, t_{j,\max}]$, 即无人机抵达时间范围存在交叉; d_k 为 2 架无人机第 k 个航迹点的欧氏距离, n 为航迹点数. 假设有 M 架无人机, 则第 i 架无人机与第 j 架无人机的协同时空约束代价函数为

$$f_{\mathrm{c}} = 1/\sum_{j=1}^{M}\left(C_{i,j}^{\mathrm{t}} + C_{i,j}^{\mathrm{d}}\right). \tag{16}$$

1.6 多无人机协同的多目标航迹代价函数

多无人机协同航迹规划问题, 既包含单个无人机的路径规划, 又涉及各机之间的时空协同性. 选取各无人机的总路径长度 l_i 和综合威胁代价 f_i 这 2 个相互冲突的目标构建适应于多无人机协同的路径规划的多目标优化模型:

$$\min\left[l_i, f_i\right]^{\mathrm{T}};\ i = 1,2,\cdots,M. \tag{17}$$

$$l_i = \sum_{k=1}^{n} d_{k-1,k}. \tag{18}$$

$$f_i = \sum_{j=1}^{n}(\sigma_1 f_{J,j}^{i} + \sigma_2 f_{H,j}^{i} + \sigma_3 f_{G,j}^{i} + \sigma_4 f_{P,j}^{m,i}) + \sigma_5 f_s + \sigma_6 f_{\mathrm{c}}. \tag{19}$$

式中: $d_{k-1,k}$ 为路径点 k-1 和 k 的欧氏距离; 在实际应用中, 须设置权重以满足需求 σ_1、σ_2、σ_3、σ_4、σ_5、σ_6 均为权重系数.

2 改进的秃鹰搜索算法

结合式 (17) 将航迹规划问题转化为多目标优化问题.

2.1 航迹编码

设定迭代中每条更新路径由种群中的秃鹰 X_i=$\{x_{i1}, x_{i2}, \cdots, x_{id}\}$构成. 在优化过程中, 利用球面矢量的幅度、仰角和方位角分量与无人机的速度、转弯角和爬升角之间的相互关系来获取更安全、高质量的解决方案[18]. 用球坐标系代替笛卡尔坐标表示秃鹰位置, 因为所有路径的起点和终点固定, 所以不包含在优化序列中, 路径由 n 个航迹点组成, 选用维度为 $3n$ 的向量序列进行表示. 这些向量在球坐标系中表示为 3 个分量, 分别为航迹距离增量 ρ、仰角 $\Psi \in (-\pi/2,\pi/2)$ 和方位角 $\Phi \in (-\pi,\pi)$. 飞行路径 $\boldsymbol{\Omega}_i$ 用超球面向量表示为

$$\boldsymbol{\Omega}_i = \left[\rho_{i1},\psi_{i1},\phi_{i1},\rho_{i2},\psi_{i2},\phi_{i2},\cdots,\rho_{iN},\psi_{iN},\phi_{iN}\right],\quad N = n-2. \tag{20}$$

航迹点 $P_{i,j}$=$(x_{i,j}, y_{i,j}, z_{i,j})$ 须转化为笛卡尔系, 转化式为

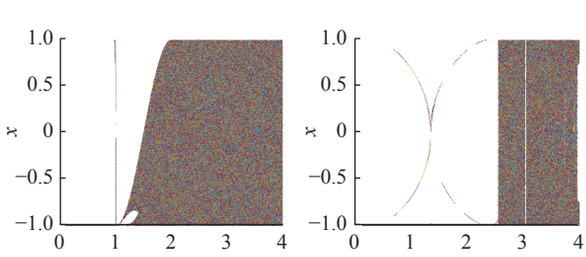
$$\left.\begin{aligned} x_{i,j} &= x_{i,j-1} + \rho_{ij}\sin\psi_{ij}\cos\phi_{ij},\\ y_{i,j} &= y_{i,j-1} + \rho_{ij}\sin\psi_{ij}\cos\phi_{ij},\\ z_{i,j} &= z_{i,j-1} + \rho_{ij}\cos\psi_{ij}. \end{aligned}\right\} \tag{21}$$

综上, 在球坐标系中秃鹰根据式 (17) 中的代价函数, 按照更新公式迭代, 逐渐收敛到最优 Pareto 前沿, 同时将秃鹰种群从角空间映射到笛卡尔坐标空间, 得到笛卡尔坐标系下的完整路径.

2.2 耦合混沌映射初始化

群体智能须维护一组解并利用启发式规则搜索最优解. 初始种群是进化过程中的起始猜想, 影响 SI 算法在寻找全局最优解时的起点, 影响种群的收敛速度和最终解的精度. SI 算法多采用伪随机数生成器 (pseudorandom number generators, PRNGs) 生成初始种群, 其原理是通过 PRNGs 生成一组服从均匀分布的随机数, 进而覆盖搜索空间中可能的区域. PRNGs 的优点是算法简单, 适用范围广. 混沌数生成器 (chaotic number generators, CNGs) 是基于混沌技术的随机数生成器, 利用一维混沌映射, 指定随机初值不断迭代, 生成一系列连续的点, 产生混乱的种群. 相比 PRNGs, CNGs 能够在种群多样性、成功率以及收敛性等方面提高群体智能算法性能. 混沌序列行为对初值和参数过于敏感, 针对不同问题须选择不同的初值和参数. 同时, 由于吸引子的存在, 混沌序列可能被吸引到几个固定的点, 影响算法效果.

本研究设计耦合混沌映射, 如图 2 所示为各混沌映射分岔图, 横轴为参数值, 纵轴为映射的状态或输出值. 由 Chebyshev 映射[20] 和 Infinite Fold[21] 混沌映射的分岔图可以看出, 当 2 个混沌映射中的控制参数分别在大于 1.0 和 1.8 时, 逐渐出现分岔现象, 因此采用耦合参数 c 级联这 2 个



(a) Chebyshev 映射[20] (b) Infinite fold 映射[21]

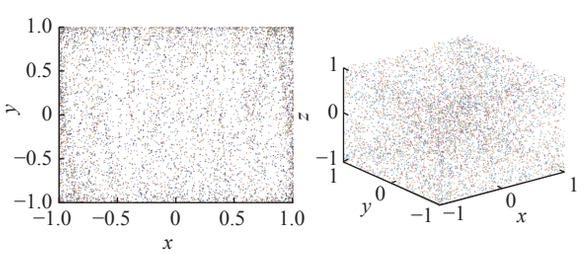
图 2 种子映射分岔图

Fig.2 Bifurcation diagram of seed mapping

种子映射，对非线性映射的混沌片段进行拼接，通过交叉迭代的方式从一维扩展到多维，其中二维情况的表达式为

$$\left.\begin{aligned} x_{i+1} &= \sin\left(\pi\left(\cos\left(3-c\right)\cos^{-1}\left(x_i\right)+\sin\left(c/y_i\right)\right)\right),\\ y_{i+1} &= \sin\left(\pi\left(\cos\left(3-c\right)\cos^{-1}\left(y_i\right)+\sin\left(c/x_i\right)\right)\right). \end{aligned}\right\} \tag{22}$$

式中：c=0.8，此时 $3-c>1.8$，2 个种子映射均出现混沌现象；i 为迭代次数. 如图 3 所示，改进后的耦合映射分岔能够减少映射空间的局部偏置，生成更均匀的种群空间，提高算法的搜索性能. 将耦合混沌映射初始化种群的 BES (CO-MOBES) 与原始多目标 BES (MOBES) 在 ZDT1 测试函数上进行对比实验，结果如图 4 所示. 图中，f_1 为测试函数的目标函数 1，f_2 为测试函数的目标函数 2. 由图可知，改进算法有效提高了初始化种群质量，pareto 前沿覆盖率较高.



(a) 二维耦合混沌映射　　(b) 三维耦合混沌映射

图 3　耦合混沌映射分岔图

Fig.3　Bifurcation diagram of coupling chaotic mapping

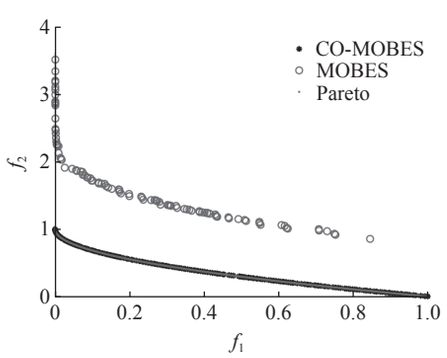


图 4　耦合混沌映射策略与原始多目标秃鹰搜索算法的代价曲线对比

Fig.4　Cost curve comparison of coupling chaotic mapping strategy and original multi-objective bald eagle search algorithm

2.3　基于“侦察鹰”的自适应高斯游走策略

多目标秃鹰搜索算法在选择和搜索阶段完成后，引导整个秃鹰种群向固定方向寻找非支配解. 由于该机制依赖前期充分探索解空间的程度，导致秃鹰个体盲目跟随最优秃鹰并逼近最优位置附近的非支配解，不进行更优解探索；若此时赋予部分秃鹰个体自主探索的能力，将会提高整体开发能力. 在此阶段引入“侦察鹰”，侦察鹰搜索机制通过自适应高斯游走策略更新个体位置，逐步调整搜索方向和步长 ς，以自适应的方式在搜索空间中进行探索求解. 设计组内均值引导，动态平衡算法探索与开发能力. 捕获阶段更新公式为

$$\varsigma == \exp\left(\frac{2.5\mathrm{rand}-1}{\left(1-I_{\max}\right)^2}\ln i\right). \tag{23}$$

$$p_{i,\mathrm{n}} = \begin{cases} G\left(p_{i,\mathrm{m}},\varsigma\right)+\left(r_1 p_{i,\mathrm{m}}-r_2 p_i\right), & p_i=\dfrac{1}{3}p;\\ \mathrm{rand}\,p_{\mathrm{b}}+\delta_x+\delta_y, & p_i=\dfrac{2}{3}p. \end{cases} \tag{24}$$

式中：r_1、r_2 均为服从 [0,1.0] 均匀分布的随机数，rand 为随机函数，随机生成 [0,1.0] 的随机数，$I_{\max}$ 为最大迭代次数，δ_x、δ_y 分别为极坐标中秃鹰的变化值，p_{b} 为当前秃鹰最好的搜索位置；$p_{i,\mathrm{m}}$ 为第 i 次迭代秃鹰更新位置的平均值，p 为种群数量，$p_{i,\mathrm{n}}$ 为第 i 次迭代秃鹰更新后的位置. 在迭代初期，高斯分布具有较大的步长 ς 以保证算法具有较强的探索能力；后期 ς 逐渐减小，提高了算法的局部开发能力. 为了削弱固定方向引导效应，通过组内均值个体引导，在其附近产生新的个体，增强侦查能力. 将基于“侦察鹰”的自适应高斯游走策略的 BES (Inves-BES) 与 MOBES 在 ZDT1 测试函数上进行对比实验，改进前后代价变化曲线对比如图 5 所示. 由图可知，改进算法寻优性能进一步提升.

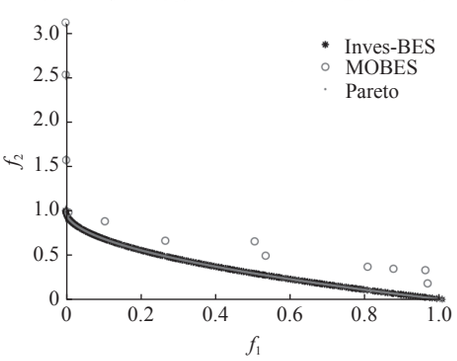


图 5　基于“侦察鹰”的自适应高斯游走策略与原始多目标秃鹰搜索算法的代价曲线对比

Fig.5　Cost curve comparison of adaptive Gauss walk strategy based on “scout eagle” and original multi-objective bald eagle search algorithm

2.4　快速非支配排序策略

相比现有的多目标排序方法（如基于网格法的非支配排序），快速非支配排序策略只与已经分配到前沿的解进行比较，无须进行所有解比较，减少了计算量. 该方法的排序步骤如下：1) 得到目标函数适应度值的矩阵，依次遍历判断支配

关系,取其中的非支配解集,构成 rank1,即得到首个 Pareto 前沿;2) 将其他解与 rank1 比较,删去其他解中由 rank1 所有个体支配的次数,若此时该解为非支配解,那么该解位于 rank2,据此逐一判断得到 rank2;3) 重复步骤 1)、2),将后面某个解与已经得到分配前沿的解进行比较,即可确定 rank3、rank4、…、rank$n$.

通过改进策略,算法不仅可以快速找到最优解,而且可以在整个解空间中保持多样性,进而在应用于多无人机协同航迹规划时具有优越的性能和效果. 将引入快速非支配排序策略的 BES (NSBES) 与 MOBES 在 ZDT1 测试函数上进行对比实验,结果如图 6 所示. 可以看出,非支配排序得到的 Pareto 前沿解精度更高.

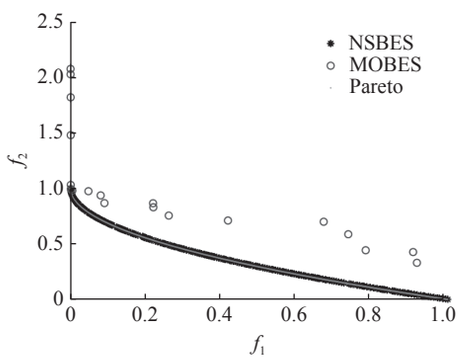


图 6　快速非支配排序策略与原始多目标秃鹰搜索算法的代价曲线对比

Fig.6　Cost curve comparison of fast non-dominated sorting strategy and original multi-objective bald eagle search algorithm

2.5　三次样条插值平滑路径随机取点算法

在无人机实际飞行中,通过三次样条平滑路径寻优航迹点. 设最终无人机避障路径 $L=\{l_1, l_2, \cdots, l_d\}$,在起点与终点之间进行三次样条插值,最终形成一条平滑航迹曲线. 针对算法运行中出现路径点过于集中的问题,前期在最优个体样条插值的平滑路径点上随机选点,使得路径点尽可能随机分布,算法流程如下. 1)种群初始化:构建三维环境模型、威胁源模型、无人机物理约束模型以及路径平滑度约束模型,确定航迹点数目与种群数目,根据式 (22) 利用耦合混沌映射初始化秃鹰种群,计算多目标代价函数,进行非支配排序. 2)迭代更新:根据秃鹰位置更新公式进行搜索. 3)边界限定:根据已限定的三维空间范围检测是否边界溢出,若溢出,则用该航迹点溢出维度的边界值代替. 4)三次样条插值随机取点获取平滑路径. 5)判断是否达到最大迭代次数,若未达到,则跳回步骤 2;否则结束.

3　改进多目标秃鹰搜索算法分析

3.1　性能测试

实验硬件仿真平台使用处理器为 12th Gen Intel (R) Core(TM) i7-12700H 2.30 GHz, 内存为 16.0 GB 的计算机,软件平台为 Matlab R2020b. 设置种群规模为 500,迭代次数为 200. 在标准测试函数集上将 IMBES 与基于网格法的多目标麻雀算法 (MOSSA)[22]、多目标鹈鹕算法 (MOPOA)[23]、多目标灰狼算法 (MOGWO)[24]、基于非支配排序的多目标蜣螂算法 (NSDBO)[25] 以及 NSGA-Ⅱ[26] 等主流算法的求解性能进行对比测试.各测试函数具体描述如表 1 所示,其中 N_{OF} 为目标函数个数.

表 1　多目标测试函数的维度和特点

Tab.1　Dimensions and characteristics of multi-objective testing functions

测试函数	N_{OF}	特点
ZDT1	2	凸, 连续
Kursawe	2	不连续, 多模态
DTLZ2	3	不连续, 多模态
DTLZ5	3	凹, 多模态
DTLZ6	3	凹, 连续
Viennet3	3	连续, 多模态

测试过程中,各测试函数分别运行 30 次,得到的 pareto 前沿箱线图如图 7 所示,其中 R 为测试结果分布范围. 可以看出,IMBES 在解决各种多目标函数方面表现出色. 对于测试函数 ZDT1,算法 MOSSA、MOGWO 和 NSDBO 都表现出相对较高的中位数,MOPOA 在中位性能上处于中等水平. 算法 NSGA-Ⅱ、MOBES 和 IMBES 的中位数相对较低,且离散度低,表明性能相对稳定. IMBES 具有最低的中位数和最佳性能. 对于 Kursawe 测试函数,NSGA-Ⅱ表现出总体稳定的性能,离群值较少,中位数属于中等范围. IMBES 具有最低的中位数,表现出更强的鲁棒性. 对于三目标函数,所提算法收敛性和覆盖率仍占优;根据没有免费午餐定理 (no free lunch, NFL)[27],不能期望算法在所有测试函数都有最好的表现,因此对于 DTLZ6 这样较为复杂的不连续多模态测试函数,IMBES 未呈现明显优势. 但 IMBES 整体寻优效果较优,说明 IMBES 在复杂交错环境中的寻优能力较强;

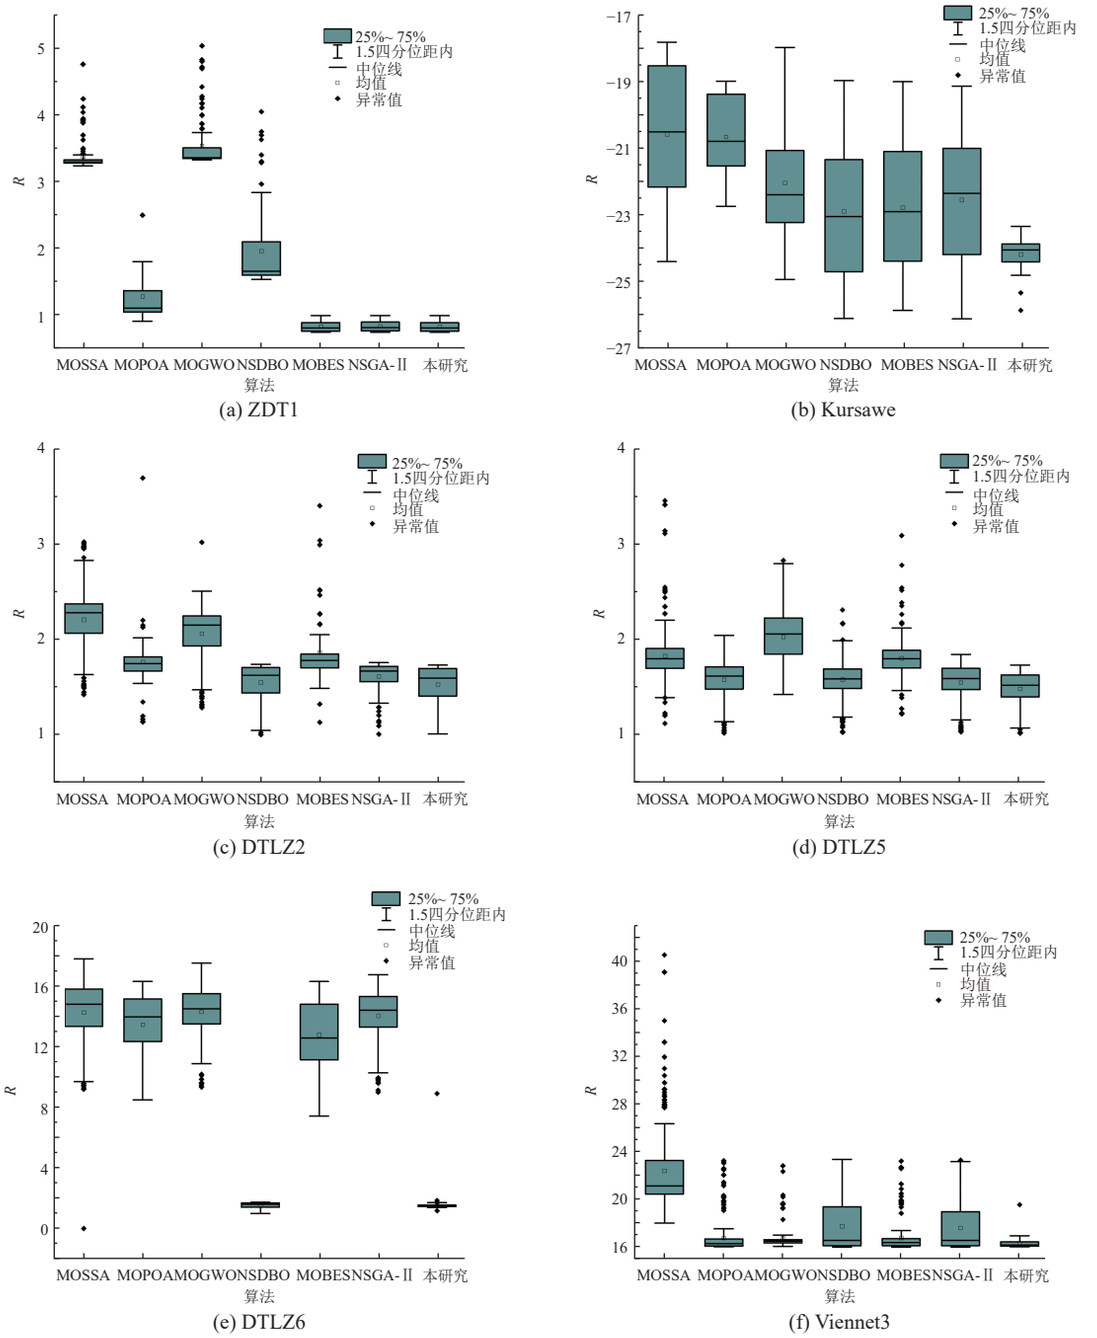


图 7 不同算法测试结果的箱线图

Fig.7 Box diagram of test results for different algorithms

MOBES 相较于 IMBES 在各个测试函数均呈现出显著优势. 6 种函数的测试结果证明了所提算法的优越性.

3.2 时间复杂度分析

设 M 为目标的个数, N 为种群大小, D 为问题维度. 在原始 BES 中, 3 个阶段位置更新的总时间复杂度为 $O(ND)\times 3$, 本研究设计的耦合混沌映射初始化的时间复杂度为 $O((N\lg N)+1)$, 基于“侦察鹰”的自适应高斯游走策略时间复杂度为 $O(1/3N)$, 引入的快速非支配排序时间复杂度为 $O(MN\sqrt{N})$, 拥挤度距离计算时间复杂度为 $O(N^2)$. IMBES 的时间复杂度为 $O(ND)\times 3+O((N\lg N)+1)+O(1/3N)+O(MN\sqrt{N})+O(N^2)$. 总体而言, 算法的时间复杂度主要受到非支配排序速度影响.

3.3 航迹点数目的影响

如表 2 所示为不同航迹点数目 n_{al} 对各群体智能优化算法的影响, 种群数目和迭代次数分别设为 500 和 200, 其中 l_t 为总路径长度, f_t 为总威胁代价, t 为耗时. 由表可知, 1) 增加航迹点数目提升了路径规划精度, 增加了决策变量, 算法因此能

表 2 航迹点数目对群体智能优化算法的影响

Tab.2 Effect of track points on swarm intelligence optimization algorithms

算法	n_{al}=12			n_{al}=16			n_{al}=20		
	l_t	f_t	t/s	l_t	f_t	t/s	l_t	f_t	t/s
MOSSA	63.601	366.390	9.89	53.583	312.926	13.22	53.943	250.575	17.63
MOPOA	63.422	**349.171**	11.28	52.964	449.868	**12.23**	54.267	243.180	**16.81**
MOGWO	63.899	546.985	9.67	53.025	460.495	12.98	52.797	230.543	16.94
NSDBO	62.343	556.647	14.51	54.790	556.073	13.20	51.940	255.942	17.83
NSGA-Ⅱ	62.804	335.403	20.08	53.104	252.541	30.06	54.245	227.363	17.69
本研究	**59.898**	339.998	**8.73**	**52.036**	**234.201**	13.11	**50.353**	**224.05**	17.90

够更好地探索搜索空间, 找到更优方案. 2) 增加航迹点数目导致计算复杂度的增加, 耗时变长, 因此在确定航迹点数目时应权衡计算复杂度和路径规划的精度. 3) 须综合考虑路径规划的精度、计算复杂度和无人机任务需求等因素来确定航迹点数目. 实验中考虑上述因素, 航迹点数目设置为 16.

4 仿真实验与分析

为了验证所提模型合理性和 IMBES 的可行性, 在仿真实验中将 IMBES 与各算法进行比较. 设置种群规模为 500, 迭代次数为 200, 航迹点数目为 16. 各算法运行 30 次, 其他主要参数设置如表 3 所示. 硬件和软件平台与第 3 节所述保持一致.

表 3 不同算法的主要参数设置

Tab.3 Main parameter settings of different algorithms

算法	主要参数
MOSSA[22]	R_2= 0.8, SD=0.1, PD=0.2
MOPOA[23]	β=1.5, R=2
MOGWO[24]	α=3, β=0.1
NSDBO[25]	p_1=0.2, p_2=0.4, p_3=0.63, k=0.1, b=0.3
NSGA-Ⅱ[26]	交叉率为0.7, 变异率为0.4, μ=0.02, δ=0.2

建立双模型增加算法的可信度, 实验如下.

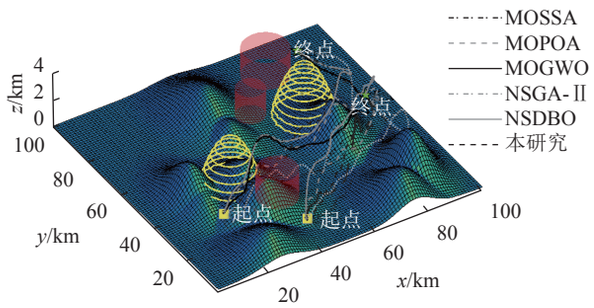
模型 1: 选取 2 架 UAV 进行仿真实验, 建立 100 km×100 km×5 km 的模拟地形区域, 实验参数如表 4 所示. 第一架无人机记作 UAV1, 航线起点为 (15,20,2), 终点为 (80,80,2). UAV2 的航线起点为 (40,10,1), 终点为 (90,55,1). 2 架无人机型号相同. 威胁源数量为 5 个, 其中雷达威胁为 2 个, 作用中心分别为 (30,40) 和 (70,60), 作用半径为 10 km, 作用效果等效为螺旋线. 禁飞区、地空导弹和防空火炮数量均为 1 个, 作用中心分别为 (35,20)、(65,75) 和 (50,60), 作用半径分别为 7、8 和 5 km, 作用效果等效为圆柱体. 如图 8 所示为各算法航迹规划结果, 各算法求解质量比较如表 5 所示, l_m 为平均路径长度, f_m 为平均威胁代价, l_s 为最短路径长度, f_s 为最小威胁代价. NSGA-Ⅱ规划出的路径较短, 但多次穿过威胁源, 威胁代价极高, 规划效果差; 其他算法均能规划出满足约束的路径. 由表 5 可知, 所提算法稳定性更高, 无论是航程代价还是威胁代价, 均得到最优的规划效果. 由图 8 可以看出, 所提算法规划的路径中, UAV1 和 UAV2 飞行路径没有发生交叉和重合, 这说明所提算法在对无人机路径协同规划问题进行寻优时实现了无人机之间的空间协同, 算法的寻优效果能够让飞行路径更短, 威胁代价更小, 耗时最短.

模型 2: 测试场景基于从激光雷达传感器获得的真实数字高程模型 (DEM) 地图[28]. 在此场景

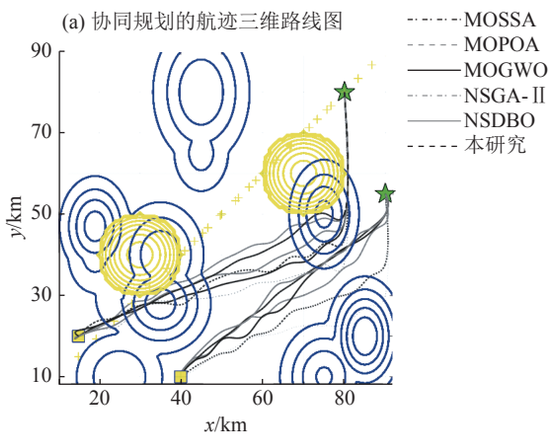
表 4 双无人机航迹规划实验的主要参数

Tab.4 Main parameters of dual UAV path planning experiment

参数	数值	参数	数值
地形威胁系数 K_H^i	100	物理约束权值 σ_1	0.2
地形威胁系数 $K_H^{i\prime}$	10	地形约束权值 σ_2	0.1
功率威胁系数 K_W	100	高程约束权值 σ_3	0.2
拐弯角威胁系数 K_α	10	威胁源约束权值 σ_4	0.2
俯仰角威胁系数 K_β	10	平滑度约束权值 σ_5	0.15
续航时间威胁系数 K_{t_d}	10	协同约束权值 σ_6	0.15
平滑度惩罚系数 λ_1, λ_2	0.5	航迹点数 d	16
威胁源修正系数 K_{thr}^m	$1/3\,K_{\max,n}^m$	—	—



(a) 协同规划的航迹三维路线图



(b) 突防路线等高线图

图 8 不同算法的航迹规划结果

Fig.8 Path planning results of different algorithms

表 5 各算法求解质量的比较（模型 1）

Tab.5 Comparison of quality of each algorithm (model one)

算法	l_m/km	f_m	l_s/km	f_s	t/s
MOSSA	53.583	312.926	52.821	241.564	4.059
MOPOA	52.964	449.868	52.329	238.592	3.879
MOGWO	**53.025**	460.495	52.232	227.393	3.144
NSDBO	54.790	556.073	52.031	257.043	3.136
NSGA-Ⅱ	53.104	252.541	52.730	234.850	3.114
本研究	52.036	**234.201**	**51.969**	**225.540**	**3.085**

下，设置 5 个威胁. 模型 2 的多架无人机协同规划轨迹结果如图 9 所示. 如表 6 所示为每种算法的解质量的比较，度量值表示实验中所有无人机的求和结果，其中 c_s 为最小威胁代价. 实验增加基于改进多目标飞蛾-火焰优化算法 (LTG-NSMFO)[29]、多目标水母搜索算法 (MOJS)[30]、NSGA-III[31] 作为对比算法. 由图可知，所提算法规划了最优路径并获得最优帕累托前沿. 由表 6 可知，所提算法在轨迹规划中表现出更高的稳定性以及最优的耗时性能，可以达到最优的规划效果. 与 MOSSA、MOPOA、MOJS、NSDBO、NSGA-Ⅲ和 LTG-NSMFO 相比，所提算法将平均路径长度缩短了 1.10~35.80 km，将平均威胁成本降低了 0.72~302.49；结

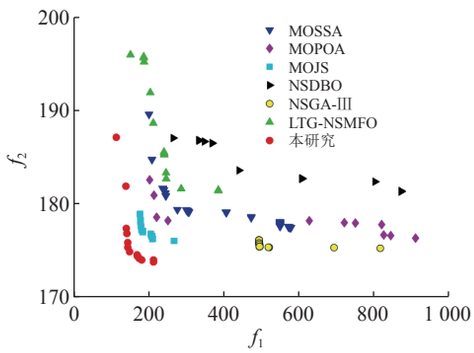


图 9 双无人机协同规划结果

Fig.9 Results of dual UAV collaborative planning

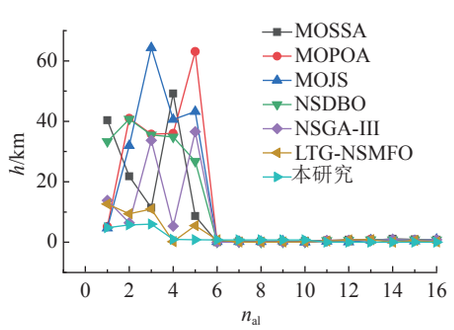
表 6 各算法求解质量的比较（模型 2）

Tab.6 Comparison of quality of each algorithm (model two)

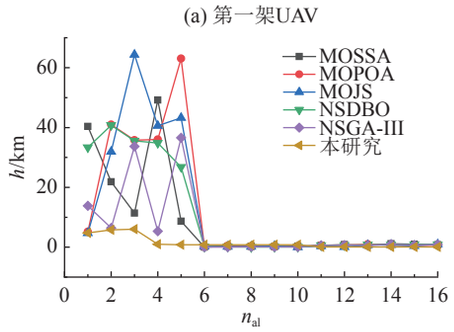
算法	l_m/km	f_m	l_s/km	f_s	t/s
MOSSA	503.59	319.05	487.89	237.46	3.639
MOPOA	512.93	206.59	499.44	139.39	3.586
MOJS	489.12	92.04	486.25	80.73	3.290
NSDBO	498.21	248.64	493.21	166.52	3.281
NSGA-Ⅲ	478.86	17.28	476.64	16.83	3.258
LTG-NSMFO	479.03	41.21	477.56	21.44	3.238
本研究	**477.13**	**16.56**	**476.49**	**14.74**	**3.105**

果表明，所提算法可以在复杂地形环境中提供可靠、高效的目标规划解决方案.

如图 10 所示为 2 架无人机在每种算法规划



(a) 第一架UAV



(b) 第二架UAV

图 10 双无人机的飞行高度变化

Fig.10 Flight altitude variation of dual UAV

路径的不同轨迹点的高度比较曲线. 可以看出, 所提算法的高度曲线最低, MOPOA 高度变化最大且整体高程代价高; 所提算法的爬升角和滑动角成本最低. MOPOA 和 MOJS 在不同飞行路径点之间的高度有显著变化, 这对无人机的性能有要求. 与 MOSSA、MOPOA、MOJS、NSDBO、NSGA-Ⅲ和 LTG-NSMFO 相比, 所提算法的无人机 1 平均飞行高度下降了 2.57~22.68 km, 无人机 2 的平均飞行海拔下降了 1.24~10.41 km.

5 结　语

本研究提出改进多目标秃鹰搜索算法并应用于多无人机协同低空突防, 解决了三维空间中多无人机协同航迹规划及自主避障问题. 定性和定量实验结果表明, 所提算法实现了快速优化, 能够为多无人机自主避障协同路径规划提供精确的路径. 此外, 所设计的模型能够解决地形和威胁源的影响, 便于深入探索复杂环境中的算法性能. 在未来的研究中, 将测试算法在城市地区的性能, 评估算法在不同测试环境和场景中的表现.

参考文献 (References):

[1] ZHANG Z, WU J, DAI J, et al. A novel real-time penetration path planning algorithm for stealth UAV in 3D complex dynamic environment [J]. **IEEE Access**, 2020, 8: 122757–122771.

[2] 王建峰, 贾高伟, 郭正, 等. 多无人机协同任务规划方法研究综述 [EB/OL]. (2023−04−19)[2024−07−29]. https://kns.cnki.net/kcms/detail/11.2422.TN.20230419.1331.010.html.

[3] PUENTE-CASTRO A, RIVERO D, PAZOS A, et al. A review of artificial intelligence applied to path planning in UAV swarms [J]. **Neural Computing and Applications**, 2022, 34: 153–170.

[4] YU X, LI C, YEN G G. A knee-guided differential evolution algorithm for unmanned aerial vehicle path planning in disaster management [J]. **Applied Soft Computing**, 2021, 98: 106857.

[5] HUO L, ZHU J, WU G, et al. A novel simulated annealing based strategy for balanced UAV task assignment and path planning [J]. **Sensors**, 2020, 20(17): 4769.

[6] YANG L, GUO J, LIU Y. Three-dimensional UAV cooperative path planning based on the MP-CGWO algorithm [J]. **International Journal of Innovative Computing, Information and Control**, 2020, 16(3): 991–1006.

[7] PAN J, LIU N, CHU S. A hybrid differential evolution algorithm and its application in unmanned combat aerial vehicle path planning [J]. **IEEE Access**, 2020, 8: 17691–17712.

[8] 黄鹤, 李潇磊, 杨澜, 等. 引入改进蝠鲼觅食优化算法的水下无人航行器三维路径规划 [J]. 西安交通大学学报, 2022, 56(7): 9–18.
HUANG He, LI Xiaolei, YANG Lan, et al. Three dimensional path planning of unmanned underwater vehicle based on improved manta ray foraging optimization algorithm [J]. **Journal of Xi'an Jiaotong University**, 2022, 56(7): 9–18.

[9] EUN Y, BANG H. Cooperative task assignment/path planning of multiple unmanned aerial vehicles using genetic algorithm [J]. **Journal of Aircraft**, 2009, 46(1): 338–343.

[10] 杜云, 彭瑜, 邵士凯, 等. 基于改进粒子群优化的多无人机协同航迹规划 [J]. 科学技术与工程, 2020, 20(32): 13258–13264.
DU Yun, PENY Yu, SHAO Shikai, et al. Cooperative path planning of multi-unmanned aerial vehicle based on improved particle swarm optimization [J]. **Science Technology and Engineering**, 2020, 20(32): 13258–13264.

[11] 闫少强, 杨萍, 刘卫东, 等. 基于 GPSSA 算法的复杂地形多无人机航迹规划 [EB/OL]. (2023–04–12)[2024–07–29]. https://doi.org/10.13700/j.bh.1001-5965.2022.0984.

[12] 袁梦顺, 陈谋, 吴庆宪. 基于 NSGA-III 算法的多无人机协同航迹规划 [J]. 吉林大学学报: 信息科学版, 2021, 39(3): 295–302.
YUAN Mengshun, CHEN Mou, WU Qingxian. Cooperative path planning for multiple UAVs based on NSGA-III algorithm [J]. **Journal of Jilin University: Information Science Edition**, 2021, 39(3): 295–302.

[13] ALSATTAR H A, ZAIDAN A A, ZAIDAN B B. Novel meta-heuristic bald eagle search optimisation algorithm [J]. **Artificial Intelligence Review**, 2020, 53: 2237–2264.

[14] YANG C, TSAI M, KANG S, et al. UAV path planning method for digital terrain model reconstruction: a debris fan example [J]. **Automation in Construction**, 2018, 93: 214–230.

[15] RADMANESH M, KUMAR M, GUENTERT P H, et al. Overview of path-planning and obstacle avoidance algorithms for UAVs: a comparative study [J]. **Unmanned Systems**, 2018, 6(2): 95–118.

[16] WAHAB S H A, CHEKIMA A, SAAD N, et al. Path planning of UAV based on fluid computing via accelerated method [J]. **International Journal of Engineering Trends and Technology**, 2020, 76–80.

[17] 黄鹤, 李文龙, 吴琨, 等. 基于 ALCE-SSA 优化的三维无人机低空突防 [J]. 南京大学学报: 自然科学, 2022, 58(3): 448–459.
HUANG He, LI Wenlong, WU Kun, et al. 3D UAV low altitude penetration optimization based on ALCE-SSA [J]. **Journal of Nanjing University: Natural Science**, 2022, 58(3): 448–459.

[18] PHUNG M D, HA Q P. Safety-enhanced UAV path planning

with spherical vector-based particle swarm optimization [J]. **Applied Soft Computing**, 2021, 107: 107376.

［19］ 周德云, 王鹏飞, 李枭扬, 等. 基于多目标优化算法的多无人机协同航迹规划 [J]. 系统工程与电子技术, 2017, 39(4): 782–787.
ZHOU Deyun, WANG Pengfei, LI Xiaoyang, et al. Cooperative path planning of multi-UAV based on multi-objective optimization algorithm [J]. **Systems Engineering and Electronics**, 2017, 39(4): 782–787.

［20］ SHAKIBA A. A novel randomized one-dimensional chaotic Chebyshev mapping for chosen plaintext attack secure image encryption with a novel chaotic breadth first traversal [J]. **Multimedia Tools and Applications**, 2019, 78(24): 34773–34799.

［21］ 邱跃洪, 何晨, 诸鸿文. 一种有限区间内无限折叠的混沌映射 [J]. 高技术通讯, 2002(9): 12–15.
QIU Yuehong, HE Chen, ZHU Hongwen. A one-dimensional chaotic map with infinite collapses [J]. **Chinese High Technology Letters**, 2002(9): 12–15.

［22］ XUE J, SHEN B. A novel swarm intelligence optimization approach: sparrow search algorithm [J]. **Systems Science and Control Engineering**, 2020, 8(1): 22–34.

［23］ TROJOVSKÝ P, DEHGHANI M. Pelican optimization algorithm: a novel nature-inspired algorithm for engineering applications [J]. **Sensors**, 2022, 22(3): 855.

［24］ NEGI G, KUMAR A, PANT S, et al. GWO: a review and applications [J]. **International Journal of System Assurance Engineering and Management**, 2021, 12: 1–8.

［25］ XUE J, SHN B. Dung beetle optimizer: a new meta-heuristic algorithm for global optimization [J]. **The Journal of Supercomputing**, 2023, 79: 7305–7336.

［26］ LIU T, YUAN Q, DING X, et al. Multi-objective optimization for greenhouse light environment using Gaussian mixture model and an improved NSGA-II algorithm [J]. **Computers and Electronics in Agriculture**, 2023, 205: 107612.

［27］ 戴晓晖, 李敏强, 寇纪淞. 遗传算法的性能分析研究 [J]. 软件学报, 2001, 12(5): 742–750.
DAI Xiaohui, LI Minqiang, KOU Jisong. Study on the performance analysis of genetic algorithm [J]. **Journal of Software**, 2001, 12(5): 742–750.

［28］ Geoscience Australia. Digital elevation model (DEM) of Australia derived from LiDAR 5 metre grid [DB/OL]. [2024–07–29]. https://doi.org/10.26186/89644.

［29］ MA M, WU J, SHI Y, et al. Research on multi-aircrafts cooperative arraying to jam based on multi-objective moth-flame optimization algorithm [J]. **IEEE Access**, 2022, 10: 80539–80554.

［30］ YI J, XING L, WANG G, et al. Behavior of crossover operators in NSGA-III for large-scale optimization problems [J]. **Information Sciences**, 2020, 509: 470–487.

［31］ CHOU J, TRUONG D. Multi-objective optimization inspired by behavior of jellyfish for solving structural design problems [J]. **Chaos, Solitons and Fractals**, 2020, 135: 109738.